PRÁCTICA 1: REGRESIÓN LINEAL

Aprendizaje Automático y Big Data

11 DE OCTUBRE DE 2018

FELIX VILLAR Y VÍCTOR RAMOS
Universidad Complutense de Madrid

1. Regresión lineal con una variable

Código:

```
import pandas as pd #Biblioteca para análisis de datos
import numpy as np #Biblioteca para operaciones numéricas
import matplotlib.pyplot as plt #Biblioteca para representar funciones

archivo = open("ex1data1.csv") #Abrimos el archivo csv
df = pd.read_csv(archivo, header=None, names=['poblacion', 'ingresos']) #Genera un dataframe con los datos
df.head(100) #Coge los 5 primeros datos del dataframe por defecto

def calc_costo(df, th0, th1):
    poblacion = df['poblacion']
    prediccion = poblacion * th1 + th0
    ingresos = df['ingresos']
    return np.sum(np.square((prediccion - ingresos)) / len(df) / 2.0)

def grad_desc(df, th0, th1, alpha):
    length = len(df)
    df['prediccion'] = df['poblacion'] * th1 + th0
    th0 = th0 - alpha / length * np.sum((df['prediccion'] - df['ingresos']))
    th1 = th1 - alpha / length * np.sum(((df['prediccion'] - df['ingresos']) * df['poblacion']))
    return th0, th1

def test_graph(df, iteraciones):
    theta0, theta1 = 0, 0
    alpha = 0.01
    costo = 0
    for elem in range(iteraciones):
        theta0, theta1 = grad_desc(df, theta0, theta1, alpha)

    costo = calc_costo(df, theta0, theta1)

    plt.plot(df['poblacion'], df['ingresos'], 'b.', df['poblacion'], df['poblacion']*theta1 + theta0, 'r-')
    plt.title('Método del gradiente')
    plt.xlabel('Población de la ciudad en 10.000s')
    plt.ylabel('Ingresos en $10000s')
    plt.text(5, 23, 'Costo: {}'.format(costo))
    plt.show()

test_graph(df, 1500)
```

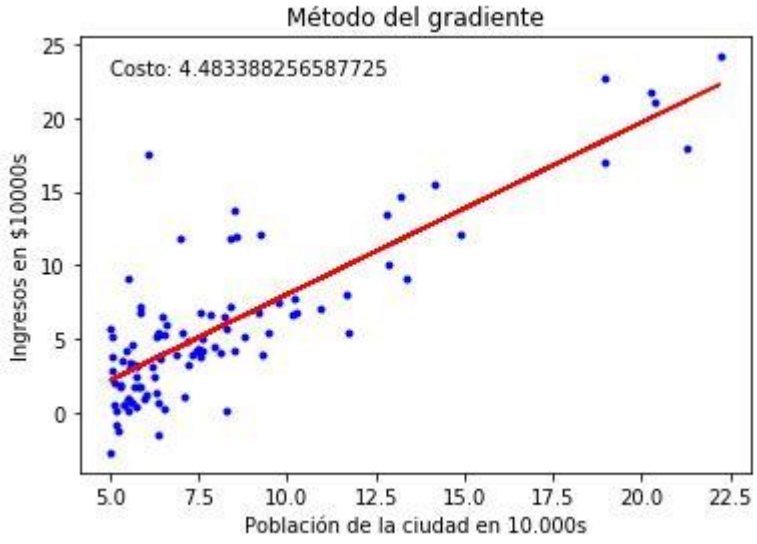

2. Regresión lineal con varias variables

Código:

```
import numpy as np

def normalizar(x):
    media = np.mean(x, axis=0)
    desv = np.std(x, axis=0)
    normalizar = (x - media) /desv
    return normalizar, media, desv

def calc_costo(entradas, salidas, th):
   prediccion = np.sum(entradas * th,axis=1)
   fun = prediccion -salidas
   return np.matmul(np.atleast_2d(fun).T,np.atleast_2d(fun))/2*len(entradas)

def grad_desc(entradas,salidas,th,alpha):
    length = len(entradas)
    prediccion = np.sum(entradas * th,axis=1)
    fun=np.multiply((prediccion - salidas)[:,np.newaxis],entradas)
    r= alpha/length*np.sum(fun,axis=0)
    th= th-r
    return th

def normec(entradas,salidas,unos):
    pob = np.concatenate((np.atleast_2d(unos).T,entradas),axis=1)
    a=np.matmul(np.transpose(pob),pob)
    b=np.linalg.pinv(a)
    c=np.matmul(b,np.transpose(pob))
    d=np.matmul(c,salidas)
    return d

def mulvar(arch, iteraciones):
    x =np.genfromtxt(arch, delimiter = ',')
    numparametros = x[0].size - 1
    unos = np.ones(int(x.size/(numparametros+1)))
    solucion = normec(x[:,:-1],x[:,-1],unos)
    entradas,media,desv = normalizar(x[:,:-1])
    entradas = np.concatenate((np.atleast_2d(unos).T,entradas),axis=1)
    salidas = x[:, -1]
    th = np.zeros(numparametros+1)
    alpha = 0.03856
    costo = 0
    for elem in range(iteraciones):
       th = grad_desc(entradas, salidas, th, alpha)
       costo = calc_costo(entradas, salidas, th)
    print('El coste de manera vectorizada')
    print(costo)

    #Ejemplo para demostrar que funciona el metodo de descenso
    #Piso con 1650 metros cuadrados y 3 habitaciones, hay que normalizar los datos
    print('La solucion de descenso de gradiente')
    print(th)
    print(th[0]+th[1]*((1650-media[0])/desv[0])+th[2]*((3-media[1])/desv[1]))
    print('La solucion de la ecuacion normal')
    print(solucion)
    print(solucion[0]+solucion[1]*1650+solucion[2]*3)


mulvar('ex1data2.csv',1500)
```

```
El coste de manera vectorizada
[[ 4.47071770e+10  4.48734107e+10 -2.92016185e+10 ... -1.11000662e+10
  -1.28780625e+10  8.86182288e+09]
 [ 4.48734107e+10  4.50402625e+10 -2.93101982e+10 ... -1.11413394e+10
  -1.29259468e+10  8.89477360e+09]
 [-2.92016185e+10 -2.93101982e+10  1.90737725e+10 ...  7.25028778e+09
   8.41163085e+09 -5.78832278e+09]
 ...
 [-1.11000662e+10 -1.11413394e+10  7.25028778e+09 ...  2.75596623e+09
   3.19741386e+09 -2.20024675e+09]
 [-1.28780625e+10 -1.29259468e+10  8.41163085e+09 ...  3.19741386e+09
   3.70957207e+09 -2.55267984e+09]
 [ 8.86182288e+09  8.89477360e+09 -5.78832278e+09 ... -2.20024675e+09
  -2.55267984e+09  1.75658384e+09]]
La solucion de descenso de gradiente
[340412.65957447 109447.79646923  -6578.35485375]
293081.4643349862
La solucion de la ecuacion normal
[89597.90954361   139.21067402 -8738.01911255]
293081.4643349892
```